

Daily Paper Bot

Hyunbeen Kim

been000904@gmail.com

NLP Team

2024/05/28



Contents

- 프로젝트 목적
- 서버 아키텍처
- 데이터세트
- 관련 논문 검색 실험
- 논문 요약 실험
- To Do

프로젝트 목적

AI 관련 주목할만한 논문이 올라오는 사이트 (<https://huggingface.co/papers>)에 올라온 논문을 가져와, 요약하고, 해당 논문과 관련 있는 논문을 이메일로 보내주는 뉴스레터 봇

☆ <2024-06-19> 오늘의 논문

📄 인쇄 | 번역

보낸사람 00tommylion00@gmail.com

2024년 6월 22일 (토) 오후 8:49

제목: DeepSeek-Coder-V2: Breaking the Barrier of Closed-Source Models in Code Intelligence

링크: <https://arxiv.org/abs/2406.11931>

요약: DeepSeek-Coder-V2는 GPT4-Turbo와 비슷한 성능을 보이며 코드 관련 작업에서 우수한 성과를 내는 오픈 소스 코드 언어 모델이다. DeepSeek-Coder-V2는 DeepSeek-V2의 중간 체크포인트로부터 추가 6조 토큰을 이용해 계속적으로 사전 훈련을 거쳐 개발되었다. 이를 통해 DeepSeek-Coder-V2는 DeepSeek-V2의 코딩 및 수학적 추론 능력을 크게 향상시키고, 일반적인 언어 작업에서도 유사한 성능을 유지하고 있다. DeepSeek-Coder-33B와 비교했을 때, DeepSeek-Coder-V2는 코드 관련 작업, 추론 및 일반적 능력의 다양한 측면에서 중요한 발전을 이루었다. 또한, DeepSeek-Coder-V2는 프로그래밍 언어 지원을 86개에서 338개로 확장하고, 맥 길이를 16K에서 128K로 확장했다. 표준 벤치마크 평가에서 DeepSeek-Coder-V2는 코딩 및 수학 벤치마크에서 GPT4-Turbo, Claude 3 Opus, Gemini 1.5 Pro와 같은 폐쇄 소스 모델들보다 우수한 성과를 거두었다.

관련 논문:


SambaNova SN40L: Scaling the AI Memory Wall with Dataflow and Composition of Experts(<https://arxiv.org/abs/2405.07518>)

Advancing LLM Reasoning Generalists with Preference Trees (<https://arxiv.org/abs/2404.02078>)

Branch-Train-MiX: Mixing Expert LLMs into a Mixture-of-Experts LLM (<https://arxiv.org/abs/2403.07816>)

Skywork-MoE: A Deep Dive into Training Techniques for Mixture-of-Experts Language Models(<https://arxiv.org/abs/2406.06563>)

서버 아키텍처



각각의 서버 컴포넌트들이 각자의 PC에서 독립적으로 실행


데이터셋

Hugging Face Daily Papers에 올라오는 논문 100일치에 대해 Abstraction,
Title에 대해 크롤링 진행, 카테고리 없는 Unlabeled Data
데이터 개수: 573개
데이터 크기: 855kb

```
{
  "2404.16710": {
    "title": "LayerSkip: Enabling Early Exit Inference and Self-Speculative Decod",
    "abstraction": "We present LayerSkip, an end-to-end solution to speed-up inf",
    "link": "https://arxiv.org/abs/2404.16710"
  },
  "2404.16811": {
    "title": "Make Your LLM Fully Utilize the Context",
    "abstraction": "While many contemporary large language models (LLMs) can prod",
    "link": "https://arxiv.org/abs/2404.16811"
  },
  "2404.16821": {
    "title": "How Far Are We to GPT-4V? Closing the Gap to Commercial Multimodal",
    "abstraction": "In this report, we introduce InternVL 1.5, an open-source mul",
    "link": "https://arxiv.org/abs/2404.16821"
  },
  "2404.16510": {
    "title": "Interactive3D: Create What You Want by Interactive 3D Generation",
    "abstraction": "3D object generation has undergone significant advancements,",
    "link": "https://arxiv.org/abs/2404.16510"
  },
}
```

관련 논문 검색 실험

관련 논문을 찾기 위한 방법으로는 Embedding, Category Tagging 방식이 있는데 더 나은 성능을 보일 것으로 보이는 Embedding 방식 실험 진행



관련 논문 검색 실험

Embedding 실험

실험 세팅

- Hugging Face Sentence Embedding 모델 사용
- Target 데이터가 없어서 통상적인 메트릭 적용하는데 한계 존재
- 데이터의 분포가 복잡하여 2 Dim에서 경향성을 보여주기 어려웠음
- K-means로 라벨링 후 메트릭 적용 및 비교
- Metric으로 Silhouette Score, Calinski-Harabasz index, Davies-Bouldin Index 사용

관련 논문 검색 실험

Embedding 실험

Clustering Metric 설명

- 실루엣 평균 (Silhouette Average, sil_avg):

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

- 클러스터 내의 데이터 포인트와 다른 클러스터 간의 거리를 비교하여 클러스터링의 품질을 측정
- 값이 클수록 데이터 포인트가 잘 군집화되어 있음을 의미

- 칼린스키-하라바즈 지수 (Calinski-Harabasz Index, ch_avg):

$$BCV = \sum_i n_i \cdot \|C_i - C\|^2$$

- 클러스터 간의 분산과 클러스터 내의 분산을 비교하여 클러스터링의 품질을 평가
- 값이 클수록 클러스터 간의 거리가 멀고, 클러스터 내의 데이터 포인트들이 더 밀집되어 있음을 의미

- 데이비스-볼딘 지수 (Davies-Bouldin Index, db_avg):

$$DB = \frac{1}{n_c} \sum_{i=1}^{n_c} R_i, \text{ where}$$

$$R_i = \max_{j=1..n_c, i \neq j} (R_{ij}), i=1..n_c$$


- 클러스터 내의 분산과 클러스터 간의 중심 거리 비율을 사용하여 클러스터링의 품질을 평가
- 값이 낮을수록 클러스터 간의 분리가 잘 되어 있고, 클러스터 내의 데이터 포인트들이 더 밀집되어 있음을 의미

관련 논문 검색 실험


Embedding 실험

Clustering Metric 설명

- 직관적으로 같은 군집내의 데이터는 가까울수록 다른 군집내의 데이터는 멀수록 클러스터링이 잘 되었다고 볼 수 있음



Red, Blue and Yellow data points before Clustering






Red, Blue and Yellow data points after Clusteing

관련 논문 검색 실험

Embedding 실험

적절한 K 찾기 (암시적으로 존재하는 논문의 주제 개수)

- 값이 크게 떨어지는 8정도에서 K 설정




관련 논문 검색 실험

Embedding 실험

적절한 모델 찾기 (모델 후보는 HF 인기모델 3종과 Openai Small Embedding)

*paraphrase-minilm-l6-v2




Embedding Dimension: 384

Silhouette Score: 0.03837

Calinski-Harabasz Score: 16.8306

Davies-Bouldin Score: 3.6319

*facebook-dpr-ctx_encoder-multiset-base




Embedding Dimension: 768

Silhouette Score: 0.0294

Calinski-Harabasz Score: 15.2897

Davies-Bouldin Score: 3.8168

*all-MiniLM-L12-v2




Embedding Dimension: 384

Silhouette Score: 0.0553

Calinski-Harabasz Score: 23.2541

Davies-Bouldin Score: 3.0838

*openai-small-embedding



Embedding Dimension: 1536

Silhouette Score: 0.0365

Calinski-Harabasz Score: 17.0258

Davies-Bouldin Score: 3.8838

관련 논문 검색 실험

Embedding 실험

실험결과

- K에 따라 순위 변동은 있었으나 all-MiniLM-L12-v2가 가장 좋은 성능보임

Silhouette Score (높을수록 좋음):

all-MiniLM-L12-v2 > paraphrase-minilm-l6-v2 > openai > facebook-dpr-ctx_encoder-multiset-base

Calinski-Harabasz Score (높을수록 좋음):

all-MiniLM-L12-v2 > paraphrase-minilm-l6-v2 > openai > facebook-dpr-ctx_encoder-multiset-base

Davies-Bouldin Score (낮을수록 좋음):

all-MiniLM-L12-v2 > paraphrase-minilm-l6-v2 > openai > facebook-dpr-ctx_encoder-multiset-base

관련 논문 검색 실험

Embedding 실험

정성 평가

Query:

Mamba (**Mamba: Linear-Time Sequence Modeling with Selective State Spaces**)

Response:

1. MambaMixer: Efficient Selective State Space Models with Dual Token(73%)
2. TransformerFAM: Feedback attention is working memory (73%)
3. Megalodon: Efficient LLM Pretraining and Inference with Unlimited Context Length (71%)

관련 논문 검색 실험

Embedding 실험

정성 평가

Query:



DreamFusion: Text-to-3D using 2D Diffusion

Response:

1. PLA4D: Pixel-Level Alignments for Text-to-4D Gaussian Splatting (81%)
2. Dual3D: Efficient and Consistent Text-to-3D Generation with Dual-mode Multi-v... (81%)
3. Controllable Text-to-3D Generation via Surface-Aligned Gaussian Splatting (79%)

논문 요약 실험

Language Model로 Downstream Task를 풀 때, 사용할 수 있는 방법이 크게 3가지가 있음 (Model Centric, Prompt Tuning, RAG) 이번에는 Model Centric 방법에 대해서만 실험 진행



논문 요약 실험

Model Centric 실험

실험 세팅

- 하고자 하는 Task에 정답 데이터가 없기에 정성 평가로 진행
- 정확한 평가를 위해 실험자가 아는 논문에 대해 쿼리 후 평가
- Chatgpt 3.5 turbo, Chatgpt 4.0 turbo, LLAMA 7B에 대해 테스트 진행
- LLAMA 한국어 성능이 많이 부족한 관계로 번역 API 사용

논문 요약 실험

Model Centric 실험

Prompt

for GPT

<paper_abstraction> + 내용에 대해 한글로 요약부탁해. 다른 말 첨가하지 말고 딱 요약만 해서 알려줘. 요약은 그래도 내용을 최대한 담아서 길게 부탁해. 잘 설명하듯 알려줘”

for LLAMA

<paper_abstraction> + Please summarize the contents in Korean. Don't add anything else, just give me a summary. Please keep the summary as long as possible and include as much content as possible. Please explain it well

논문 요약 실험

Model Centric 실험

Input (“Attention is all you need” Abstract)

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English-to-German translation task, improving over the existing best results, including ensembles, by over 2 BLEU. On the WMT 2014 English-to-French translation task, our model establishes a new single-model state-of-the-art BLEU score of 41.8 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the best models from the literature. We show that the Transformer generalizes well to other tasks by applying it successfully to English constituency parsing both with large and limited training data.

Output

In GPT3.5 Turbo

(about “Attention is all you need”)

Transformer는 순환 및 컨볼루션 신경망 없이 attention 메커니즘에만 기반한 신경망 구조로, 기존의 모델보다 훨씬 우수한 성능과 더 빠른 학습 시간을 요구한다. 영어-독일어 및 영어-프랑스어 번역 작업에서 기존 최고 성능을 뛰어넘는 결과를 얻었으며, 작은 비용으로도 상위 BLEU 점수를 달성하였습니다. Transformer는 다른 작업에도 성공적으로 적용되며, 대규모 및 제한된 학습 데이터를 활용한 영어 문장 구문분석에도 잘 일반화됨을 보여줍니다.

In GPT4.0 Turbo

(about “Attention is all you need”)

본 연구에서는 순환 신경망이나 합성곱 신경망 대신 전적으로 어텐션 메커니즘에 기반한 새로운 네트워크 구조인 트랜스포머를 제안합니다. 이 모델은 기존의 복잡한 인코더-디코더 구조를 사용하지 않으면서도 훨씬 뛰어난 병렬 처리 능력과 훈련 시간 단축을 실현합니다. 트랜스포머는 WMT 2014 영어-독일어 번역 작업에서 28.4 BLEU를 달성하여 기존 최고 성능 모델들을 2 BLEU 이상 상회하였고, 영어-프랑스어 번역 작업에서는 41.8 BLEU로 새로운 단일 모델 최고 성과를 기록하였습니다. 이는 8개 GPU를 사용하여 3.5일 동안 훈련하여 달성한 결과로, 기존 모델 대비 훨씬 적은 비용으로 이루어졌습니다. 또한 트랜스포머는 영어 구문 분석 작업에도 효과적으로 적용되어, 풍부한 데이터와 한정된 데이터 모두에서 좋은 일반화 성능을 보이는 것으로 나타났습니다.

In LLAMA 7B

(about “Attention is all you need”)

Transformers는 자연어 처리(NLP) 분야에 혁명을 일으킨 딥러닝 모델 클래스입니다. 기계 번역, 텍스트 생성, 질문 답변과 같은 작업에 매우 효과적인 것으로 나타났습니다. 이 기사에서는 NLP의 변환기 및 해당 응용 프로그램에 대한 개요를 제공합니다.

논문 요약 실험

Model Centric 실험

Input (“DDPM” Abstract)

We present high quality image synthesis results using diffusion probabilistic models, a class of latent variable models inspired by considerations from nonequilibrium thermodynamics. Our best results are obtained by training on a weighted variational bound designed according to a novel connection between diffusion probabilistic models and denoising score matching with Langevin dynamics, and our models naturally admit a progressive lossy decompression scheme that can be interpreted as a generalization of autoregressive decoding. On the unconditional CIFAR10 dataset, we obtain an Inception score of 9.46 and a state-of-the-art FID score of 3.17. On 256x256 LSUN, we obtain sample quality similar to ProgressiveGAN. Our implementation is available at <https://github.com/hojonathanho/diffusion>.

Output

In GPT3.5 Turbo
(about “DDPM”)

확산 확률 모형에 영감을 받은 잠재 변수 모형 중 하나인 확산 확률 모형을 이용한 고품질 이미지 합성 결과를 제시합니다. 저희가 얻은 최고의 결과는 확산 확률 모형과 노이즈 스코어 매칭 및 랑게빈 다이내믹스를 통한 새로운 연결에 따라 설계된 가중치 변형한 바운드에 기반하여 훈련하는 것으로, 저희 모델들은 자연스럽게 자동회귀 디코딩의 일반화로 해석될 수 있는 점진적 손실 압축 체계를 허용합니다. 무조건적 CIFAR10 데이터셋에서 9.46의 인셉션 점수 및 3.17의 최신형 FID 점수를 얻습니다. 또한 256x256 LSUN에서 우리는 ProgressiveGAN과 유사한 샘플 품질을 얻습니다. 저희 구현은 이 [https](https://github.com/hojonathanho/diffusion) URL에서 이용 가능합니다.

In GPT4.0 Turbo
(about “DDPM”)

우리는 열역학의 비평형 고려에서 영감을 받은 잠재 변수 모델인 확산 확률 모델을 사용하여 고품질의 이미지 합성 결과를 제시합니다. 최상의 결과는 확산 확률 모델과 탈잡음 점수 매칭 및 랑제뱅 동역학 사이의 새로운 관계에 따라 설계된 가중 변분 바운드를 훈련하여 얻었습니다. 또한, 우리의 모델은 자기회귀 디코딩의 일반화로 해석될 수 있는 점진적인 손실 압축 해제 체계를 자연스럽게 허용합니다. 조건 없는 CIFAR10 데이터셋에서 우리는 인셉션 점수 9.46과 최첨단 FID 점수 3.17을 달성했으며, 256x256 LSUN에서는 ProgressiveGAN에 필적하는 샘플 품질을 달성했습니다. 우리의 구현은 제공된 HTTPS URL을 통해 확인할 수 있습니다.

In LLAMA 7B
(about “DDPM”)

이 보고서에서는 이미지 합성을 위한 확산 확률 모델 사용에 대한 연구 결과를 제시합니다. 우리는 확산 확률 모델과 Langevin 역학과 일치하는 잡음 제거 점수 사이의 새로운 연결에 따라 설계된 가중 변분 범위에서 확산 모델을 훈련함으로써 우리 접근 방식의 효율성을 입증합니다. 우리 모델은 일반화로 해석될 수 있는 점진적인 손실 압축 해제 방식을 자연스럽게 인정합니다.

논문 요약 실험

Model Centric 실험

실험 결론

- 정성 평가에 그칠 수 밖에 없었던 것 같아 아쉬움, 좋은 지표 서베이가 필요
- Llama는 확실히 별로인 것 같고, GPT3.5가 가장 효율적일 것으로 보임

To Do

RAG 기반 요약 실험

다양한 요약 Policy 정해보고 실험해보기

더 나은 임베딩 스페이스 찾기 (학습 필요할수도)

Category Tagging 기반 연관 논문 검색 실험

서비스 확장 (기능 정의)



TRAIN AND TEST